

## TP Hadoop Python (4h)

S. Derrode

### 1. PRISE EN MAIN

Chaque élève dispose d'un compte pour accéder au serveur Big-Data/Hadoop de la plateforme Amigo de l'École Centrale de Lyon :

*mso31\_y*, où *y* désigne le numéro qui vous sera attribué par l'encadrant du TP.

Merci de retenir ce numéro car il vous sera utile lors des prochains TP. Le mot de passe est identique au compte. Ce compte vous est accessible durant toute la durée du module. Il sera ensuite détruit dans le courant du mois d'avril, pensez à faire une copie sur votre ordinateur perso (commande « *scp ...* »).

Pour vous connecter sur votre compte, dans un terminal, tapez « *ssh -Y login@156.18.90.100* » où *login* est votre compte. Entrez ensuite le mot de passe. Vous devriez alors voir apparaître un message similaire à :

```
>> ssh -Y sderrode@156.18.90.100
sderrode@156.18.90.100's password:
Warning: No xauth data; using fake authentication data for X11 forwarding.
Last login: Sun Jan  8 07:25:06 2017 from vpn96-192.vpnusers.ec-lyon.fr
Welcome to Bright release 7.3

Based on CentOS Linux 7
ID: #000002

Use the following commands to adjust your environment:
'module avail' - show available modules
'module add <module>' - adds a module to your environment for this session
'module initadd <module>' - configure module to be loaded at every login
-----
[sderrode@bright73 ~]$
```

On peut apprendre, grâce aux traces, que le serveur fonctionne sous *CentOS Linux 7* (une distribution de *Linux* parmi d'autres), et que le système de gestion du cluster *Hadoop* s'appelle *Bright* (ou *Bright Cluster Manager*).

Ça y est, vous êtes connecté au serveur de la DSI qui simule un data center. Comme vous pouvez le constater, il n'y a pas d'interface graphique, et la manipulation des fichiers doit se faire à la main. Il faut donc connaître un minimum de commandes *Linux* à taper sur le Terminal (aussi appelé 'invite de commande' ou 'console' en fonction des systèmes d'exploitation).

Avant de commencer, vous devez télécharger l'ensemble des fichiers (de tous les TPs), grâce à un dépôt *github*. Vous devez d'abord configurer *git* :

1. >> *git config --global user.name "votre nom"*  
# enregistrement par git de votre nom.
2. >> *git config --global user.email "votre adresse mail"*  
# enregistrement par git de votre adresse mail.
- 3.>> *git config --global color.ui auto*  
# active la colorisation de la sortie en ligne de commande

Pour se faire, ouvrez un terminal et déplacez-vous dans un répertoire de travail. Tapez ensuite les commandes suivantes :

```
>> git clone https://github.com/SDerrode/tp-hadoop-python.git
>> cd tp-hadoop-python
>> ls
```

Vous verrez apparaître plusieurs répertoires. Entrez dans le répertoire « *Hadoop* » qui correspond au répertoire de ce TP.

## 2. WORDCOUNT, HADOOP STREAMING

*Note : Pour éviter les problèmes de copier-coller entre l'énoncé (pdf) et votre terminal, j'ai concaténé toutes les commandes dans un fichier « Commandes.txt ».*

Il s'agit ici d'exécuter les programmes vus en cours, dans différentes configurations, sur les 5 tomes de l'œuvre de V. Hugo, « Les Misérables »<sup>1</sup>.

1. Exécution en local,  
`chmod +x *.py` (rendre exécutable tous les scripts python)  
`cat ../Livre/LesMiserables_T4.txt | wc_mapper.py`  
`cat ../Livre/LesMiserables_T4.txt | wc_mapper.py | sort -k1,1 | wc_reducer.py`  
`cat ../Livre/LesMis*.txt | wc_mapper.py | sort -k1,1 | wc_reducer.py`
2. Copiez les 5 tomes sur votre espace HDFS, en utilisant les commandes suivantes :  
`hdfs dfs -mkdir LivreHDFS`  
`hdfs dfs -put ../Livre/LesMis*.txt LivreHDFS`

Le serveur Hadoop est en panne ! Les commandes commençant par « `hadoop jar...` » ne pourront pas s'exécuter. A titre d'exercice, écrivez les commandes 3. et 4. en local et testez-les.

3. Exécution sur HDFS  
`export STREAMINGJAR='/cm/shared/apps/hadoop/Hortonworks/2.7.3.2.5.0.0-1245/share/hadoop/tools/lib/hadoop-streaming-2.7.3.2.5.0.0-1245.jar'`  
`hadoop jar $STREAMINGJAR -files wc_mapper.py,wc_reducer.py -mapper wc_mapper.py -reducer wc_reducer.py -input LesMiserables/LesMis*.txt -output sortie`  
`hdfs dfs -ls sortie` (vous devriez voir un fichier `_SUCCESS`, vide mais dont la seule présence marque le succès du job, et un autre appelé `part-0000`, contenant les résultats du job).  
`hdfs dfs -cat sortie/part-00000`  
`hdfs dfs -rm -r -f sortie` (pour supprimer le répertoire de sortie entre 2 exécutions)
4. Tester les programmes `wc_mapper_improved.py` et `wc_reducer_improved.py`  
`hadoop jar $STREAMINGJAR -files wc_mapper_improved.py,wc_reducer_improved.py -mapper wc_mapper_improved.py -reducer wc_reducer_improved.py -combiner wc_reducer_improved.py -input LesMiserables/LesMiserables_T1.txt -output sortie`
5. Modifier le programme précédent de telle manière que la sortie ne contienne que les mots dont la fréquence est supérieure à une valeur fixée (par exemple 10). N'oubliez pas de rendre exécutable vos nouveaux fichiers python (« `chmod +x zzz.py` »).

## 3. LIBRAIRIE MRJOB

**Documentation** : <https://media.readthedocs.org/pdf/mrjob/latest/mrjob.pdf>

1. Tester les programmes `wc1_mrjob.py` et `wc2_mrjob.py`, en utilisant les commandes suivantes :  
`python3 wc1_mrjob.py ../Livre/LesMiserables_T1.txt`  
`python3 wc1_mrjob.py ../Livre/LesMiserables_T4.txt --mapper`  
`python3 muw_mrjob.py ../Livre/LesMiserables_T1.txt -r local`  
`python3 wc2_mrjob.py ../Livre/LesMiserables_T4.txt -r hadoop`  
`# python3 muw_mrjob.py hdfs:///user/sderrode/LesMiserables/LesMiserables_T1.txt -r hadoop`  
(n'oubliez pas d'adapter le `loggin` à votre compte)  
`python3 muw_mrjob.py hdfs:///user/sderrode/LesMiserables/LesMiserables_T1.txt -r hadoop --`  
`output_dir hdfs:///user/sderrode/sortie/ --no_output`  
`hdfs dfs -ls sortie`  
`hdfs dfs -cat sortie/part-00000`  
`python3 wc2_mrjob.py LesMiserables_T4.txt -r local --jobconf mapred.red.tasks=3 --output_dir`  
`sortie --no_output`  
`hdfs dfs -ls sortie`  
`hdfs dfs -text sortie/part-0002`

<sup>1</sup> Le livre est dans le domaine public. Connaissez-vous « Project Gutenberg » : <http://www.gutenberg.org> ?

2. Il s'agit maintenant de développer un algorithme hadoop/mrjob permettant de multiplier une matrice (supposée très grande) avec un vecteur de dimension adéquate (pas de contrôle sur les dimensions). Nous appellerons la classe *MRMatrice*. Voici les différentes étapes pour arriver au but :
- La matrice est codée dans un fichier appelé *matrice.txt* de la manière suivante :

```
0 1 2 3
1 2 3 4
2 3 4 5
```

La première colonne représente le numéro de ligne, alors que les 3 autres colonnes donnent les valeurs de la matrice. Puisqu'elles sont numérotées, l'ordre des lignes n'a ici que peu d'importance.

- Outre les méthodes *mapper*, *combiner* et *reducer* que nous avons déjà vues, MRJob prévoit une méthode dont la signature est « *def mapper\_init(self)* ». Cette méthode est appelée une unique fois au début de chaque *mapping*. **ATTENTION : avec cette solution, on lit le fichier vecteur pour chaque ligne de la matrice : ce n'est pas très efficace !**

Utilisez cette méthode pour définir le vecteur à multiplier :

- Dans une première version de l'algorithme, le vecteur sera codé en dur, sous forme d'une liste de valeurs, par exemple « vecteur = [2, 4.5, 6] », pour faire vos tests. Le programme python sera appelé *matrice1\_mrjob.py*.
- Dans une seconde version, *matrice2\_mrjob.py*, le vecteur sera lu dans un fichier dont le nom sera passé sous forme un argument lors de l'exécution :

```
python3 matrice2_mrjob.py matrice.txt --vector vector.txt -r inline
```

Pour cela, vous pouvez utiliser le système prévu par MRJob pour transférer des options au programme, en ajoutant la méthode suivante :

```
def configure_args(self):
    super(MRMatrice, self).configure_args()
    self.add_file_arg('--vector')
```

sachant qu'il est possible de retrouver le contenu transféré au programme par le biais de l'option « *vector* » (c'est à dire le nom du fichier) grâce à l'instruction « *self.options.vector* ».

- Intégrez à votre programme un *combiner* pour réduire les transferts de données entre mappers et reducers. Le programme Python correspondant sera appelé *matrice3\_mrjob.py*. *Remarque* : Si le *combiner* est identique au *reducer*, il suffit d'écrire « *combiner = reducer* » dans la classe. Il n'est donc pas besoin de recopier la méthode !
- Tester le programme sur *BigMatrice.txt* et *BigVecteur.txt* stockés sur : ~~*hdfs:///user/shared/*~~. Constatez que les données du vecteur de sortie ne sont pas nécessairement dans le bon ordre. Comment régler ce problème ?

#### 4. PROJET : REDUCE SIDE JOIN

(depuis le tutorial : <https://www.edureka.co/blog/mapreduce-example-reduce-side-join/>)

Nous allons ici développer un programme MapReduce pour réaliser une opération de jointure (ala SQL). Une opération de jointure consiste à combiner 2 bases de données. Par exemple, les entreprises maintiennent généralement deux tables séparées pour leurs clients et pour les achats réalisés par ces clients. Il est alors bien souvent nécessaire de fusionner ces 2 tables pour calculer des quantités comme « Quelle la plus grosse somme dépensée par un client ce mois-ci ? ». Pour répondre, il faut réaliser une jointure entre ces deux tables en utilisant une colonne commune (la clé étrangère), comme l'identifiant du client.

Les deux fichiers associés à cet exercice se nomment : « *cust\_details* » et « *transaction\_details* », et présente les résultats de gestion d'un réseau de salles de fitness. Nous chercherons à connaître :

- La fréquence de visite des salles de sport de chaque client (quelle que soit la salle) ;
- Les sommes dépensées par chaque client depuis que le fichier de transactions existe.

Dans le « *reduce side join* », le *reducer* est responsable de la jointure. Il est plus facile à implémenter que le « *map side join* » car les phases de mapping et de shuffling envoient des paires qui ont la même clé au même *reducer*, et les données sont ainsi organisées par défaut.

**Truc :** Vous disposez d'un seul *mapper* pour traiter les 2 fichiers, ce qui est problématique. Vous pouvez distinguer les deux fichiers par le nombre de leurs colonnes.

**Notes finales :**

- La contrepartie de la simplicité du « *reduce side join* », c'est qu'il génère un énorme trafic réseau.
- Quand on veut réaliser une telle jointure, on préférera utiliser Apache Hive (écosystème Hadoop), qui est un langage SQL-like destiné à traiter de gros volumes de données HDFS.
- Il existe une version « *map side join* » de la jointure, plus performante lorsque l'un des deux fichiers est beaucoup plus petit que le second, et qu'il peut tenir en mémoire vive.